

# RLT 交互记忆研究的实验执行指南

这份指南把英文论文中的假设转换成当前 Zeva 分支可以依次完成的开发与实验任务。先验收仿真 baseline；通过后再在一个分支完成“正确的记忆输入—可学习的经验表征—匹配预算的控制收益—冻结参数后的经验收益”闭环，再扩展迁移和真机。当前最该补的是证据与训练目标，不是更大的网络。

日期：2026 年 10 月 3 日。目标：CVPR 2027。这是研究执行计划；下文明确区分当前可执行命令、需要开发的能力与已观察结果。本次只编写和验证材料，没有启动新训练。两组 baseline / attention 只读预检均通过；它们检查路径和配置，不代表本次运行过 GPU rollout。

10 月 3 日发布修订：先验收仿真 baseline，再开发 Stage 1B 与新记忆模块。AlphaBrain / LIBERO 目前仅完成源码和公开结果核查，尚未在本项目运行。下面第 4、11、13 节已按这一先后关系调整，方法和现有开发数据的证据边界不变。

[查看仓库对比与验收条件](#)

英文论文 v2：16 页 LaTeX 论文已按 eRLT / SmoothRL 的单栏研究论文结构重写。已测诊断放在正文第 5.1-5.2 节，待测控制及迁移协议放在第 5.3-5.6 节，代码现状与公式放在附录。指南中的执行顺序保持：baseline 验收 → 小规模对照 → Stage 1B → 冻结参数适应 → 留出迁移。

v2 进一步区分：critic 沿用 baseline 的 committed action 定义；交互记忆记录真实执行前缀。不要把执行后才知道的时长直接增加为当前 critic 的输入。初版检索采用固定相似度，learned retrieval 留作消融；没有新增实验结果。

## 1. 先把研究主张定准确

建议论文主线为：

冻结 VLA 提供当前场景与任务的表征；已经完成的动作及其真实后果提供执行条件的证据。我们学习如何把这种证据压缩为可检索、可更新的条件表征，供 RLT 的小 actor / critic 使用，并检验它是否降低在线交互成本、支持参数冻结后的适应，以及能否在相容的新条件中复用。

这里有三层“经验”，不能混写。replay 中的 transition 通过 RL 更新权重，是 baseline 已有的学习机制；运行时 memory 改变下一次决策的输入，是要单独验证的无梯度适应；跨任务复用 source bank 才涉及记录层面的迁移。权重迁移与记忆迁移必须分别做对照。

“物理规律”暂时用操作性定义：表征包含对后续命令响应有预测价值的信息。它可以隐式表达执行条件，但不直接等于摩擦系数、刚度、接触力，更不能仅凭预测误差称为因果辨识。机器人不动可能是接触，也可能是饱和、限位或控制器响应不足。

投稿主张只保留实验能支持的部分。若最终只有 q-only 响应统计有效，就需要缩小“视觉交互表征”的表述；若 memory 只改善预测、不改善控制，就不能继续写“加速 RL 收敛”。

## 2. 当前代码与拟开发方法分别是什么

| 环节           | 当前 Zeva 实现                                 | 论文拟开发版本                                     |
|--------------|--------------------------------------------|---------------------------------------------|
| Stage 1      | 原 VLA action SFT 与 RL token 训练             | 第一轮完全复用既有 checkpoint                        |
| Stage 2 视觉坐标 | VLA / RL token 冻结                          | 保持冻结                                        |
| 一条经验         | 原始起始 q、执行动作前缀、原始 $\Delta q$ 、有效步 mask、结束标记 | 再加入历史 z 与真实后继 z，并学习 event encoder           |
| 短期与 archive  | 最近 4 条；archive 容量 32；另检索 4 条               | 先保持预算，后比较视觉 + 关节检索                          |
| 检索           | 起点 q 距离                                    | 当前视觉与本体条件；不能使用隐藏物理参数                        |
| 读取器          | attention，或无参数 response                    | Stage 1B 训练的 64 维 interaction context       |
| 训练信号         | 默认 reader 只受 critic TD 更新                  | 过去历史辅助预测后续动作结果；初版 Stage 2 冻结 reader         |
| 使用位置         | 小 actor / critic                           | 保留接口，先不改 action expert                      |
| 跨尝试          | 可选，相同实例检查后保留 archive                       | 增加冻结参数下 retain / clear / shuffle 评估         |
| 跨任务迁移        | 尚未实现                                       | 独立 source bank，限定相同 robot / controller / 单位 |

当前 110 维记录为  $9 + 10 \times 8 + 9 + 10 + 2$ 。记录真实执行的动作，不是 actor 输出后未被选中的候选；发生 terminal 时不把未执行尾部当作有效动作；先取得真正的终止后继，再 reset。

当前 actor 输入为 `[ref_chunk, z_rl, proprio, memory.detach()]`，critic 为 `[z_rl, proprio, memory, action]`。读取器归 critic optimizer 管，不能再通过 actor optimizer 重复拥有。原始 q 与经过 VLA transform 的 proprio 不是同一数值坐标。

| 需要阅读或修改的文件                                                            | 当前责任 / 下一步                                                                       |
|-----------------------------------------------------------------------|----------------------------------------------------------------------------------|
| <code>rlinf/models/embodiment/openpi/pi0.py</code>                    | 核查 Stage 1 action expert 与 token 训练，不把 noisy demonstration hidden state 当作部署可见输入 |
| <code>rlinf/models/embodiment/modules/rlt_token_transformer.py</code> | 原 token 压缩与重建；先保持不变                                                              |
| <code>rlinf/algorithms/rlt/interaction_memory.py</code>               | 执行记录、有限容量、快照、reset 语义；扩展 schema 必须版本化                                            |
| <code>rlinf/models/embodiment/modules/rlt_memory_encoder.py</code>    | attention / response 接口；新增 pretrained context 的载入与冻结                             |
| <code>rlinf/models/embodiment/mlp_policy/rlt_mlp_policy.py</code>     | actor / critic 条件拼接与梯度边界                                                         |
| <code>rlinf/workers/actor/fsdp_rlt_ac_policy_worker.py</code>         | critic 所有权、chunk 折扣、BC 与 Q 更新；路径已核实                                              |
| <code>toolkits/rlt/probe_memory_dynamics.py</code>                    | 现有预测诊断；可复用数据处理思路，不能当完整 Stage 1B                                                  |
| <code>run_rlt_portable.sh</code>                                      | GPU 隔离与预检；需补正式 variant / seed / routing 参数                                       |
| <code>examples/embodiment/config/experiment/rlt_memory.yaml</code>    | 现有 overlay；新模块应保持配置显式、可追溯                                                        |

### 3. 最小方法：让历史表征为未来结果提供信息

训练样本严格按时间构造：过去记录  $\rightarrow$  当前条件  $c_t$   $\rightarrow$  当前实际执行动作  $\rightarrow$  后续  $\Delta q / z$ 。 $c_t$  中只能包含已经完成的旧事件。预测头可以读取训练目标对应的动作，但不能读取其结果；这条动作完成后才能写入下一个 memory。

第一版采用 64 维 event/context，128 隐藏维、两层轻量时序编码器、4 个 attention heads。保留动作顺序与 valid mask；先做  $q$  变化 Huber loss 和后续  $z$  的 cosine loss。选择直接预测作为初始 latent head，保留 residual 对照。权重从  $\lambda_q=1$ 、 $\lambda_z \in \{0, 0.1, 1\}$  开始，按训练集标准化，并只用 validation 选配置。它们是起始设定，不是已有最优参数。Zeva 已有前 / 后交互后果预测，因此这一 loss 属于借鉴；reader 训练接到 RLT 上是否形成足够的新贡献，仍取决于直接近邻对照和新的实证发现，不能由叙事保证。

不能只让 encoder 重建自己输入的  $\Delta q$ 。那样只证明会压缩记录，不证明对下一步有用。训练目标必须是后续、互不重叠的 chunk；同一 trajectory / pair 的所有窗口进入同一 split。norm、候选 bank、统计阈值均不得接触测试数据。

先用固定 horizon 的有效非跨 reset 窗口建立预测诊断。完整 terminal transition 仍可用于 RL；预测数据若排除了 terminal，需要单独报告筛选比例与终止附近误差。不能把“已经成功所以提前结束”的长度或 success flag 作为免费未来提示。用于线上 residual 检测时，必须在执行前固定预测 horizon，并明确反馈对应哪一次预测。

Stage 1B 先离线学 encoder / reader / decoder，Stage 2 初版冻结前两者，只训练 actor / critic，保留全部 baseline 参数。这样可以检查“已有可用经验坐标是否帮助 RL”。之后再比较 TD + 辅助预测在线更新 reader；若更新，则旧 replay 保留原始快照并重新编码，缓存 key 需要版本控制。

失败数据进入两条路径：真实后果训练 predictor；真实 reward 与 successor 训练 critic。不要把失败动作自动加入正向 BC。奖励用于任务价值，不默认写进可迁移的物理 event。接触标签若取自 simulator，只能是明确标注的 privileged auxiliary supervision，测试 policy 不得读取。

#### Stage 1B 的最小数据与 checkpoint contract

拟新增缓存每行包含 trajectory\_id, chunk\_id, start\_z, next\_z, start\_q[9], next\_q[9], executed\_actions[10,8], valid\_ticks[10], true\_terminal, truncation, controller\_schema\_id。视觉  $z$  的实际维度从固定 Stage 1 checkpoint 读取，不在数据脚本另写一份常数。raw  $q$  必须来自执行环境，不能从归一化 proprio 反推而不核对 transform。source task 和隐藏 physics 标签只用于 split / 分析，与模型输入字段分开保存。

样本 builder 先按完整 trajectory/pair 划分 train / validation / test，再在各自 split 内构造“前四条 + 旧 archive”的快照。训练时重建 past-only bank；测试 source bank 仅来自训练源任务。缓存需要 Stage 1 权重 hash、controller 单位、action scale、simulator revision、训练集 normalizer 与 schema version。若 successor 是 reset 后状态，丢弃预测样本并修复 collector；不能把它当随机噪声继续训练。

拟新增的 Stage 1B trainer 只载入缓存，训练 event encoder、reader 和预测头，导出包含架构参数、normalizer、schema version、Stage 1 hash、weights 和 validation 选择依据的 checkpoint。Stage 2 严格核验这些字段。第一版 decoder 不参与 actor 推理；需要 residual 监测时另测其时延。测试覆盖 future-record 排除、paired split、空记忆、terminal/padding、checkpoint 不匹配拒绝和冻结参数边界。模块名与 CLI 需开发后再确定，本文没有把未实现脚本当可执行入口。

## 4. 先完成 baseline 验收

以下是执行顺序与验收条件，不是已经完成的实验，也不承诺固定小时数内收敛。暂缓新增 Stage 1B、action-expert 约束和多种记忆网络。

| 阶段            | 执行内容                                                                                    | 通过条件                                                    | 两张卡如何使用                                      |
|---------------|-----------------------------------------------------------------------------------------|---------------------------------------------------------|----------------------------------------------|
| A：公开模型复评      | 固定 AlphaBrain 604924b，加载配套 Qwen VLA 与 RLT_a 发布权重；先 task 0 / 3 / 6 各 20 回合，再完整 10×50 回合。 | 相同初始状态与动作协议；保存逐回合记录。小样本不能直接比较公开整体 92%。                  | GPU 0：VLA-only；GPU 1：发布模型。先从少量环境 worker 测资源。 |
| B：重新训练两阶段     | 优先尝试同仓库 full-token RLT 与已验收的 Qwen VLA。显式提供 Stage 1 demonstration 配置；随后训练 Stage 2。       | BC warmup 保持基本能力；实际采样和更新计数正常；保存 / 恢复后的动作与评估一致。          | 先一个 seed 排查，再并行不同 seed；环境数量由实测吞吐和内存决定。       |
| C：确认 baseline | 至少 3 个训练 seed，在有成功样本且未饱和的任务上对比初始 VLA。                                                   | 同时记录无辅助成功率、环境 step、有效 chunk、wall-clock 和成功轨迹数；报告波动及负结果。 | 同一实现、同一训练预算。正式关键对照再扩到 5 个 seed。              |
| D：交互记忆对照      | 仅在 baseline 通过后，比较 none / recent / attention / response，再开发 consequence reader。         | 统一初始化、routing、数据和交互预算；后续独立测试 retain / clear 与条件变化。      | 两张卡跑匹配组或不同 seed，不同时更换多个模块。                   |

RLT\_a 的公开 92% 与 full-token RLT 不是同一方法；前者用于验收仿真链路，后者仍需独立重训。若必须保持  $\pi 0.5$ ，需要先确认配套 checkpoint 与数据，不能把 Qwen 结果当  $\pi 0.5$  复现。Stage 2 不要求 VR，仿真可提供奖励；没有纠正数据时仍需确认初始 VLA 能采到成功轨迹。

原 ManiSkill 路线保留作为历史证据与候选实现。其 12 小时 memory run、关键阶段 baseline 和短 smoke 采用不同控制与预算，不能直接比较。原先建议的 2,000 chunks 只是 pilot 预算示例，正式预算应由实测吞吐和 baseline 学习曲线确定。

### 当前能直接运行的预检

以下保留的是 ManiSkill 历史预检入口，不是 AlphaBrain 命令。公开版本使用 RLT\_REPO 与 RLT\_ENV 占位变量，需要先设置为自己的项目目录和环境目录。命令只验证现有配置和资源路径，不启动训练、不创建 Ray 服务。两个命令应分别检查 GPU 0 和 GPU 1。

```
cd "${RLT_REPO}"
RLINF_VENV="${RLT_ENV}" \
RLT_PHYSICAL_GPU=0 RLT_SMOKE_PROFILE=overnight \
RLT_SMOKE_STEPS=2 RLT_EPISODE_STEPS=500 \
bash run_rlt_portable.sh --check
```

```
cd "${RLT_REPO}"
RLINF_VENV="${RLT_ENV}" \
RLT_PHYSICAL_GPU=1 RLT_SMOKE_PROFILE=overnight \
RLT_SMOKE_STEPS=2 RLT_EPISODE_STEPS=500 \
bash run_rlt_portable.sh --memory --check
```

当前 `run_rlt_portable.sh --memory` 固定选择 attention overlay，没有正式的 seed / reader / routing 参数入口。不要通过设置一个未被脚本读取的环境变量，误以为已经切换 response 或种子。当前 overnight 辅助路径继承 `always_on`，正式关键阶段 baseline 使用不同 routing；所有对比必须统一。

以下是拟开发的配置需求，不是可复制执行的命令：

`variant={none,recent,attention,response,consequence}`、`seed`、`routing={auto,always_on}`、固定 valid-tick 预算、冻结 encoder 选项、memory reset 规则、无专家与固定专家预算、独立评估 reset IDs。应使用同一 launcher 与不同静态 Hydra overlay，避免为每个方法复制一套脚本。

## 5. 先补的工程约束

1. 实验矩阵能真实切换。response 无可训练 memory 参数，不能沿用 `audit_adapter --prefix memory_encoder. --require-change` 的成功条件；它应验证 actor / critic 更新、响应特征正确、无意外参数，而非要求固定读取器变化。模型 shape 改变时不能直接续训旧 Stage 2 ckpt。
2. **replay** 恢复覆盖 **cache eviction**。小到没有淘汰的 resume smoke 不够。保存文件、index、sample count、trajectory counter 与分 rank 恢复需要一致；恢复后再次 append / sample 也要正确。现有 runtime memory 不自动随 Ray 环境恢复，应明确 reset，不声称 bitwise mid-episode resume。
3. 执行与时序一致。改动 joint memory 时验证被 routing 选中的动作、提前 terminal、真正 terminal successor、partial reset、owned snapshot、NaN padding 和 all-empty attention。测试应放现有对应 component 文件，不按 bug 新建一堆文件。
4. 单位明确。`pd_joint_delta_pos` 归一化 command 与 rad 不可直接相减；当前 response arm scale 为 0.1，必须核对实际 controller。视觉 latent 与经过 transform 的 proprio 也不能当原始物理量。旧预测诊断把旋转臂关节与直线手指坐标一起平均，不能把整体 MSE 解释成  $\text{rad}^2$ ；新实验应分别报告 arm / finger 误差及训练集标准化后的聚合误差。
5. 证据输入可部署。隐藏 stiffness/friction、真实接触标签、task success、oracle phase 不能悄悄进入物理 context。若 baseline 原有 phase gate 用 simulator state，单列披露并所有组保持一致。

变更应在同一个 `research/rlt-zeva-interaction-memory` 研究分支连续完成，以固定 revision 划分实验，不再并行扩大 FLARE / VR 支线。远程 `abb43823` 与本地 `f2d1cf64` 的差异先单独查看；本次没有合并。

## 6. 两张卡上的正式矩阵与停止条件

优先级不是一次跑完所有方法。先确认一个插入任务，再扩展到三个任务家族；更窄孔洞只能算同任务几何条件。

| 阶段    | 对比                                                                     | 种子 / 评估                               | 开始下一阶段的依据                    |
|-------|------------------------------------------------------------------------|---------------------------------------|------------------------------|
| P0：工程 | baseline、attention、response 的短跑及恢复                                     | 每组 1 次，固定边界测试                         | 配置、动作、计数、梯度与保存正确             |
| P1：表征 | current-only、recent、archive、response、consequence；补 no-action / shuffle | 3 个初始化；按 trajectory group 统计          | 新 held-out pair 上有可重复的有效信息读取 |
| P2：闭环 | original RLT、capacity control、recent、attention、response、consequence    | 首轮 3 个训练种子；每轮 validation 20 回合；正式测试另留 | consequence 在相同预算下有值得确认的控制信号 |

| 阶段         | 对比                                            | 种子 / 评估                | 开始下一阶段的依据                |
|------------|-----------------------------------------------|------------------------|--------------------------|
| P3：机制      | 固定参数下 retain / clear / shuffle；5 次尝试          | 配对 100 个实例起步；多训练 seed  | 每次尝试的收益不能仅由多次抽样解释        |
| P4：扩展      | 三任务家族；eRLT-style、prediction-only；必要消融         | 核心差异争取 5 seeds；次级不少于 3 | AUC、最终成功、wall-clock 结论相容 |
| P5：迁移 / 突变 | related / unrelated / empty source bank；旧条件切换 | 单独保留未见物理值和任务实例         | 量化负迁移、恢复和稳定场景代价          |

P1 的 no-action 消融必须同时去掉 history event 中命令信息与 predictor 当前动作输入，另补“只去掉其中一处”的定位对照；仅将当前动作置零、保留历史动作，会回答不同问题。shuffle 需在相同记录数量、任务/几何分层中打乱，避免把简单分布外破坏误解为因果证据。评估时突然清空记忆可能有分布偏移，训练中加入预先固定比例的空记忆样本，并报告 train/test protocol。

预先指定继续投入的开发标准，例如 3 个 seed 中至少 2 个方向一致、平均成功 AUC 的绝对差至少 0.03，且 wall-clock 没有明显恶化。它只是资源分配阈值，不是统计显著性或发表门槛。开发阈值在看下一轮新数据前固定；确认阶段按置信区间与预注册主对比判断。

如果只有预测提升，先做 reader 使用诊断、匹配 optimizer / BC 权重、观察 actor 是否忽略 context；允许一轮预定的修正预算。仍无控制收益就停止扩张 archive、改讲负结果或调整问题。若固定 response 最好，不要为了神经叙事隐藏它；先证明额外视觉和时间结构能解决它失败的场景。

### 计算预算以实际 **profile** 修订

从 10 月 3 日到正文截止约 44 天，理想容量为两卡约 2,112 GPU-hours。按 65% 可用于正式实验估算约 1,373 GPU-hours，其余留给调试、重跑与评估；这只是容量规划，不是已测运行时间。

| 工作包                            | 暂定上限              | 说明                                |
|--------------------------------|-------------------|-----------------------------------|
| 核心三任务 × 六组 × 三 seed            | 648 GPU-hours     | 按每次 12 小时估算，先 profile；达到总预算则压缩次要组 |
| 关键 baseline / method 补到五 seed  | 144 GPU-hours     | 三任务 × 两组 × 两新增 seed               |
| eRLT-style / prediction-only   | 144 GPU-hours     | 先一任务、三 seeds、两组，不直接扩到全矩阵          |
| 表征训练、Zeva-style CTE 对照、关键消融与评估 | 约 250 GPU-hours   | 只有通过前序门槛才支出                       |
| 合计                             | 约 1,186 GPU-hours | 留有约 187 小时机动；超过估计就删次要消融           |

单卡独立作业优先，不为小 actor / critic 强行使用两卡 DDP。将 GPU 与方法交叉分配或随机分配，避免方法始终绑定同一卡；不同作业独立输出目录、Ray 端口和 GPU 锁。正式报告给出环境 ticks 与 GPU-hours，不能拿 outer iteration 数作为统一交互成本。

## 7. 怎样验证记忆、迁移和旧经验失效

记忆收益。从同一训练 checkpoint 出发冻结全部权重，固定实例初态与物理条件，做五次尝试。retain 只保留允许的 archive，clear 每次清空，shuffle 用等数量错配经验。成功后仍继续安排剩余尝试，避免后面的尝试只剩困难实例。分别报告第 k 次无条件成功率、先前失败条件下成功率、累计成功率；累计成功率自然随尝试数上升。

迁移收益。相同 target weights 分别加载空 bank、相关 source bank、无关但等数量 bank、错误物理条件 bank。同时比较“已预训练 encoder 但空 bank”与未预训练初始化，区分权重迁移。source 使用训练任务，目标测试数据不得写回 source bank；target temporary memory 在实例之间清空。先限定同机器人、动作坐标、控制器与单位；跨 embodiment 不放进第一版贡献。

条件变化。先只改变一个能从 simulator 读回验证的参数，避免同时改 stiffness、friction、delay 后无法解释。比较不清理、立即清理的 oracle 上界、固定遗忘、只用观测残差的清理。报告突变后前 K 步损失 / 失败、恢复所需有效 ticks、稳定条件误清理率、最终成功。延迟反馈绑定 prediction ID / generation；旧代反馈不能再次重置新代 memory。

接触与碰撞。插入成功本来需要接触。不能把所有 contact 都当负事件；指定冲击阈值、积分时间和单位，区分正常约束接触、过大冲量和反复无效推进。真机没有力传感器时，q 响应只能提供歧义证据。先报告可测的“重复无效动作”和 simulator contact proxy，不写真实安全性提升。

## 8. 统计表必须怎么记

每个 episode 至少保存 method, training\_seed, checkpoint, task, split, instance\_id, attempt\_id, physical\_condition\_id\_for\_analysis, memory\_protocol, valid\_ticks, success, intervention\_ticks, wall\_time。隐藏物理标签只进入分析文件，不能进入 policy observation。每个训练 checkpoint 同时记录训练 ticks、更新次数、GPU-hours、source data 成本。

主指标为按固定 interaction horizon 归一化的 success AUC；配合最终成功率、达到固定成功阈值所需 ticks 和 successes/hour。没达到阈值是右删失，不能丢掉后只平均达标 run。低成功率任务不要用成功回合平均长度掩盖大量失败。

统计以训练 seed 和实例分层做 paired bootstrap；同一 trajectory 的窗口不当独立样本，五次 retry 也不当五个独立训练 seed。三 seeds 只能提供较弱的不确定性估计，核心对比尽量补到五 seeds。100 回合在  $p \approx 0.5$  时单纯二项抽样 95% 半宽约 10 个百分点；若要证明最终成功率“不下降超过 5 个百分点”，需要更精确的评估，而不能用“不显著”代替等效。

预先固定一个主对比和主指标，其他确认性对比分组控制多重比较；预测头超参数只看 validation。最终 test 到实验冻结后再运行，不能每次调参都查看。

## 9. 现有证据只能支持哪些结论

| 已有观察                                                         | 可以支持                      | 不能支持                |
|--------------------------------------------------------------|---------------------------|---------------------|
| 无历史 MSE $1.8211e-4$ ；attention $1.8143e-4$ ；固定公式 $7.3889e-5$ | 数据中有响应信息，当前神经 reader 利用不足 | 新方法有效、任务成功提高、未见刚度泛化 |

| 已有观察                                                | 可以支持                    | 不能支持                 |
|-----------------------------------------------------|-------------------------|----------------------|
| support-gated 总体 MSE 2.4417e-5 ; late 1.6588e-5     | 补偿在历史充分时可避免破坏固定估计；改善冷启动 | support 是置信度、发现物理规律  |
| 12 小时 memory run , 516 outer steps , 4 回合评估         | 训练路径可运行                 | 收敛更快或稳定 25% 成功       |
| 新版 324 个 synthetic 方法×条件×seed 评估记录的版本保护（方法间复用配对数据流） | 延迟反馈时序归属需要修复            | 324 次机器人操作成功，接触适应已成立 |

所有旧 split 均视为 development 数据。它们已经用于选方向，下一轮确认要新建独立 scene / command groups。英文初稿表 4、表 5 是已测开发证据，表 6 是待填正式结果；不能在摘要中把待测提升写成过去时。

## 10. 文献定位与必须面对的反驳

英文文稿附 25 篇核实元数据的原始研究文献；查阅截止为 2026 年 10 月 3 日。广泛调研不等于穷尽所有并行工作，投稿前还需再次检索。

| 审稿人的问题                                 | 必需的回答 / 实验                                                                                                                |
|----------------------------------------|---------------------------------------------------------------------------------------------------------------------------|
| 这是否只是 RLT + Zeva ?                     | Zeva 本来已有 pre/post effect prediction ; 不能把预测 loss 当新贡献。补 Zeva-style CTE + 同一 RLT controller 对照，并用闭环收益、冻结记忆干预与可迁移性建立新的实证结论 |
| eRLT 已改善 RL token，你的瓶颈是否仍存在？           | 加强 current representation 的对照；若 gap 消失，收缩 memory 必要性结论                                                                    |
| RMA、UP-OSI、PEARL 早已从历史适应？              | 承认先例；贡献限定到 frozen VLA 控制、视觉执行证据、有限经验复用与实际预算                                                                               |
| Imagine-RL 已有预测与 residual confidence ? | 不宣称首次预测式 critic / 置信门控；本主方法是记忆条件与严格时序监督，无候选动作 planning                                                                    |
| 只是更多训练数据或参数？                           | source 数据共享、capacity control、总计算成本表                                                                                       |
| “利用失败”有什么新意？                           | 承认 replay 已利用失败；展示失败带来的可迁移执行表征与 context 作用                                                                                |
| 为什么投 CVPR ?                            | 视觉一动作一后果共同建模、真实视觉歧义场景、visual-memory 消融与多任务视觉控制证据                                                                          |
| 人工干预更少的证据？                             | 仿真只报告固定规则 correction proxy；真人分钟数留真机测量                                                                                     |

最接近原文：RLT、eRLT、Zeva、Imagine-RL、FLARE。完整条目、作者、链接见随附 `references.bib` 和 `references.json`。

## 11. 投稿排期

CVPR 2027 官方 CFP 指定：注册 11 月 10 日 AoE，正文 11 月 16 日 AoE，补充材料 11 月 23 日 AoE。AoE 为 UTC-12；若截止按当日 23:59，分别对应北京时间次日 19:59。以官方提交页面最终倒计时为准，不把时区转换当额外延期。官方提示非机构邮箱创建的新 OpenReview profile 审核可能需要两周，因此现在就确认全部作者账号，不等注册前几天。

| 日期            | 研究交付                                                                         |
|---------------|------------------------------------------------------------------------------|
| 10 月 3-6 日    | 固定候选实现，复评公开权重并验收 baseline 训练链路；立即确认所有作者 OpenReview profile                   |
| 10 月 7-12 日   | 先完成三 seed baseline 验收；通过后做 memory 最小对照及 consequence reader。未通过则顺延方法扩展，缩小投稿主张 |
| 10 月 13 日     | 第一次 go/no-go：有无可重复的控制信号；没有则停止扩网络                                             |
| 10 月 14-24 日  | 三任务家族主实验；必要近邻比较；冻结参数重试                                                       |
| 10 月 25-31 日  | source-bank 迁移、条件突变；核心对比补 seeds                                              |
| 11 月 1-6 日    | 实验冻结、统计、失败案例、论文正文与图表定稿                                                       |
| 11 月 7-10 日   | 核对作者与 OpenReview 信息、正式注册、模板与匿名检查                                             |
| 11 月 11-15 日  | 复核主张—证据对应、最终 PDF 和复现资料                                                       |
| 11 月 16 日 AoE | 正文截止；内部截止至少提前一天                                                              |
| 11 月 23 日 AoE | 补充材料截止；不把关键未完成主实验全部推迟到补充                                                     |

初稿是扩展版科研文档，尚未套用官方页数与匿名模板。最终模板和 author guidelines 以 2027 当届发布内容为准。完整故事并不保证录用；如果到 10 月中旬仍没有公平闭环结果，优先调整目标而非包装预测诊断。

## 12. 官方 RLinf 持续跟踪

本次读到官方 main：c70606f08cdca259b8dec03d4430926b5b8fac9d。对比上次的 034579c，新增 #1645 并发 group 创建修复，已于 10 月 2 日合并。对 Ray 并发启动有潜在关联，但没有本地回归结果前不把它写成实验性能修复。

| PR / 变更                           | 10 月 3 日状态          | 本研究的适用性                                 |
|-----------------------------------|---------------------|-----------------------------------------|
| #1623 replay checkpoint           | Open；页面显示 6 commits | 优先：cache 淘汰后保存 / 恢复；长实验前单独验证            |
| #1645 scheduler concurrent groups | Merged              | 启动稳定性；单独评估是否回移                          |
| #1572 effective replay cache      | 已进入 main            | 核查本地 effective config 行为，不能仅看默认参数       |
| #1571 replay prefetch errors      | 已进入 main            | 长实验错误传播；不要误判卡死为性能问题                     |
| #1570 per-rank RNG                | 已进入 main            | 与本地 checkpoint backend 和 rank 设置分别核对    |
| #1639 reward default              | Open                | 当前环境 reward 路径与未来 learned reward 路径分别核查 |
| #1641 empty reward splits         | Open                | 训练 reward classifier 时再纳入必查             |
| #1635 OpenVLA action chunks       | Open                | 当前 OpenPI 路径不直接套用；保留环境 transition 合同检查  |

执行习惯：每次研究开发开始及每轮新 campaign 前，检查官方 main 和 recently updated PR；保存日期、revision、状态、影响判断。进行中的实验固定 revision。上游合并并不意味着自动更新本地实验，先独立验证，再将所有相关组统一放到新 revision。网络失败就记录“未验证”，不沿用旧状态冒充最新。

当前已将这一习惯写入仓库 AGENTS 指令；本次没有配置后台定时任务，也没有自动合并上游。随附 `upstream_commits.json`、`upstream_prs.json` 是本次只读检查快照。

## 13. 现在首先做的一件事

---

在独立环境固定 AlphaBrain 版本，整理两卡评估入口并复评配套公开模型。先确认观测变换、动作单位、controller、chunk 长度和逐回合记录，再重新训练 Stage 1 / Stage 2。公开模型复评通过也不等于从头训练已经稳定。baseline 验收前，Stage 1B 和新的 memory 结构保持为研究提案。

完整的执行依据见10月3日仿真 baseline 核查；所有新训练结果须另建带 revision、配置与评估协议的实验记录。